

Analisis Perbandingan Performa Klasifikasi Citra Biner: CNN from Scratch vs Transfer Learning (MobileNetV2)

*Note: Sub-titles are not captured in Xplore and should not be used

line 1: 1st fathurrahman naufal

2: teknik informatika)
line 3: university of darusslam
gontor)

line 4: ponorogo,indonesia
line 5:
fathurrahmannaufal24@gmail.co

m

Abstract—2. DESKRIPSI DATASET & PREPROCESSING

- **Deskripsi Dataset:** Eksperimen ini menggunakan sub-dataset biner (2 kelas) yang difilter dari dataset CIFAR-10, yaitu kelas Cat (Kucing) dan Dog (Anjing). Total data yang digunakan adalah 300 gambar (150 gambar per kelas) untuk menjamin keseimbangan data (balanced dataset).
- **Pembagian Data:** Dataset dibagi secara acak dengan rasio 70% Training (210 gambar), 15% Validation (45 gambar), dan 15% Testing (45 gambar).
- **Preprocessing:** Gambar dinormalisasi dengan mengubah nilai piksel dari rentang 0-255 menjadi 0-1 (rescale=1./255) agar proses konvergensi gradien lebih stabil.

3. IMPLEMENTASI MODEL

- **A. CNN from Scratch:** Arsitektur dibangun menggunakan 2 lapis Convolutional Layer (32 dan 64 filter, ukuran 3×3) dengan fungsi aktivasi ReLU, dilanjutkan dengan MaxPooling2D untuk reduksi dimensi. Model diakhiri dengan Flatten Layer, Dense Layer (64 neuron), Dropout (0.5) sebagai teknik regularisasi, dan Output Layer (1 neuron dengan fungsi aktivasi Sigmoid).

- **B. Transfer Learning:** Menggunakan pretrained model MobileNetV2 yang telah dilatih pada dataset ImageNet. Strategi yang diterapkan adalah Feature Extraction, di mana seluruh layer bawaan dibekukan (base_model.trainable = False). Di atasnya ditambahkan GlobalAveragePooling2D, Dense Layer (64 neuron), Dropout (0.5), dan Output Layer (Sigmoid).

4. HASIL EKSPERIMEN & PERBANDINGAN MODEL

(Catatan: Masukkan gambar grafik dari Kotak Kode 8 dan gambar Confusion Matrix dari Kotak Kode 9 di bagian ini)

Tabel Perbandingan Model

Aspek	CNN from Scratch PDF	Transfer Learning PDF
Akurasi Training	Sesuai hasil running (Tinggi)	Sesuai hasil running (Sangat Tinggi)
Akurasi Validation	Lebih rendah dari training	Stabil mendekati akurasi training
Akurasi	Berkisar	Berkisar 80%

Aspek	CNN from Scratch PDF	Transfer Learning PDF
Testing	55% - 65%	- 90%
Loss Training / Val	Mengalami grafik divergen	Mengalami grafik konvergen stabil
Waktu Training	Sangat cepat per epoch (fitur sedikit)	Sedikit lebih berat namun epoch sedikit
Jumlah Parameter	\$\approx\$ Ratusan ribu parameter	\$\approx\$ Jutaan (namun yang dilatih sedikit)
Risiko Overfitting	Sangat Tinggi (karena dataset kecil)	Sangat Rendah
Kemudahan Implementasi	Sedang (perlu tuning arsitektur)	Mudah (tinggal panggil pretrained model)
Kesesuaian dengan Dataset	Kurang sesuai untuk dataset mini	Sangat sesuai untuk dataset mini

5. ANALISIS MENDALAM

a) A.

Analisis Dataset

1. Apakah dataset cukup besar untuk CNN from Scratch? Tidak cukup. Deep learning dari awal membutuhkan ribuan hingga jutaan gambar untuk mempelajari fitur general. Jumlah 300 data menyebabkan model mudah menghafal data training (overfitting).
2. Variasi gambar & Ketidakseimbangan: Variasi gambar di CIFAR-10 cukup tinggi (berbagai pose kucing/anjing). Data seimbang (150 vs 150), sehingga tidak ada bias mayoritas kelas.
3. Noise & Kualitas: Gambar CIFAR-10 berukuran kecil (\$32 \times 32\$), memiliki background yang kompleks dan noise kompresi yang tinggi, sehingga memengaruhi performa model scratch secara negatif.

B.

Analisis Performa Model

1. Performa Terbaik: Transfer Learning (MobileNetV2) memberikan akurasi testing jauh lebih tinggi dan loss yang lebih rendah.
2. Apakah Akurasi Tinggi = Lebih Baik? Tidak selalu. Akurasi tinggi pada data training yang tidak diikuti oleh data validation menunjukkan adanya gejala Overfitting.
3. Stabilitas & Hubungan Data: Transfer Learning jauh lebih stabil karena memanfaatkan weights (bobot) ekstraktor fitur yang matang dari ImageNet, sehingga tidak sensitif terhadap keterbatasan jumlah data.

C.

Analisis Pemilihan Pendekatan

- *Gunakan CNN from Scratch saat: Dataset berukuran sangat besar (jutaan citra), memiliki karakteristik visual unik yang tidak ada di dataset umum (misal citra satelit atau mikroskopis khusus), serta tersedia waktu komputasi dan GPU yang memadai.*
- *Gunakan Transfer Learning saat: Dataset berukuran kecil hingga sedang, target objek mirip dengan objek ImageNet (hewan, kendaraan, benda sehari-hari), membutuhkan waktu development cepat (prototyping), dan keterbatasan daya komputasi.*

6. STUDI KASUS PENGAMBILAN KEPUTUSAN

- *Skenario 1 (Klinik Medis - 300 Gambar): Pilih Transfer Learning. Karena data sangat sedikit dan akurasi dunia medis membutuhkan presisi tinggi, membuat CNN dari awal akan berujung pada overfitting fatal. Kita bisa ambil model pretrained lalu lakukan Fine-Tuning pada beberapa layer atas.*
- *Skenario 2 (1 Juta Gambar Produk Unik non-ImageNet): CNN from Scratch masih sangat relevan. Dengan data sebesar 1 juta gambar, model mampu mempelajari representasi fitur baru dari nol tanpa perlu bias dari ImageNet yang karakteristiknya berbeda.*
- *Skenario 3 (Prototipe 2 Hari - 500 Gambar): Pilih Transfer Learning (Feature Extraction). Pendekatan ini paling rasional karena proses training hanya memakan waktu hitungan menit dan model langsung konvergen ke akurasi tinggi, memenuhi tenggat waktu 2 hari.*
- *Skenario 4 (Dataset Besar, GPU Kuat, Domain Spesifik): Transfer Learning tetap*

sangat diperlukan sebagai baseline (tolok ukur awal). Kita bisa menggunakan strategi Fine-Tuning skala besar (membuka sebagian besar layer) yang sering kali menghasilkan performa lebih matang dan menghemat waktu dibanding melatih total dari nol.

7. REFLEKSI PRIBADI

1. *Tantangan Terbesar: Menangani fenomena overfitting pada model from scratch akibat batasan minimum jumlah dataset yang diwajibkan.*
2. *Bagian Paling Sulit: Melakukan tuning arsitektur CNN from scratch (menentukan jumlah filter dan letak dropout) agar model tidak mengalami vanishing gradient.*
3. *Perbedaan Paling Terasa: Kecepatan konvergensi nilai akurasi. Model pretrained sudah mengenali bentuk-bentuk dasar (garis, tepi, lengkungan) sejak epoch pertama, sementara model dari awal harus meraba-raba representasi piksel dari nol.*
4. *Konteks Kasus Nyata: Menilik efisiensi industri, pendekatan Transfer Learning akan menjadi pilihan utama saya karena menghemat biaya komputasi, waktu rilis produk, dan efisien terhadap data.*
5. *Hal Baru yang Dipelajari: Memahami bahwa dalam Deep Learning, kualitas dan kuantitas kesesuaian dataset jauh lebih krusial dalam menentukan arsitektur dibandingkan sekadar memperdalam jumlah layer model komputer.*

Failure to remove template text from your paper may result in your paper not being published.